

Deteksi Dini Kesehatan Mental Mahasiswa dengan Machine Learning: Perbandingan Algoritma Decision Tree dan Random Forest

Jayadi Jayadi¹, Vito Hafizh Cahaya Putra^{*2}, Agung Rachmat Raharja³, Muhammad Al-Husaini⁴

¹ Program Studi Informatika, Fakultas Teknik, Universitas Ma'Soem

² Program Studi Informatika, Fakultas Teknologi Kreatif, Universitas Satu, Indonesia

³ Program Studi Teknik Informatika, Fakultas Kesehatan dan Teknik, Universitas Bandung, Indonesia

⁴ Program Studi Informatika, Fakultas Teknik, Universitas Siliwangi

Informasi Artikel:

Dikirim: 11-11-2025; Diterima: 21-12-2025; Diterbitkan: 05-01-2026

Doi : <http://dx.doi.org/10.31602/tji.v17i1.21251>

Kesehatan mental di kalangan mahasiswa merupakan isu yang semakin penting untuk diperhatikan, mengingat tingginya tekanan akademik dan sosial yang dapat memicu stres, kecemasan, hingga depresi. Penelitian ini bertujuan untuk menerapkan dan membandingkan dua algoritma machine learning, yaitu Decision Tree dan Random Forest, dalam mendeteksi potensi depresi pada mahasiswa berdasarkan data yang tersedia. Dataset yang digunakan diperoleh dari Kaggle dan mencakup berbagai variabel psikososial seperti tekanan akademik, stres finansial, dan riwayat pemikiran bunuh diri. Tahapan penelitian meliputi praproses data, pelatihan model, evaluasi performa menggunakan 5-fold cross validation, serta analisis feature importance. Hasil evaluasi menunjukkan bahwa model Decision Tree memiliki rata-rata F1 Score sebesar 0.8217, sementara Random Forest menunjukkan nilai 0.8098. Meskipun Decision Tree unggul secara metrik evaluasi dan efisiensi komputasi, Random Forest lebih stabil dan tahan terhadap overfitting. Kesimpulan dari penelitian ini merekomendasikan penggunaan algoritma Random Forest untuk sistem deteksi dini depresi mahasiswa, dengan tetap mempertimbangkan kelebihan Decision Tree dalam hal interpretasi hasil.

Keywords: *Kesehatan Mental, Mahasiswa, Machine Learning, Decision Tree, Random Forest, Deteksi Depresi.*



This is an open-access article under a Creative Commons Attribution 4.0 International ([CC-BY 4.0](https://creativecommons.org/licenses/by/4.0/)) License. Copyright ©2026 by authors.

Pendahuluan

Kesehatan mental di antara mahasiswa merupakan isu yang semakin mendapat perhatian dalam bidang pendidikan [1]. Tekanan akademik, tuntutan sosial, dan ketidakpastian masa depan merupakan faktor-faktor yang memicu peningkatan tingkat stres, kecemasan, dan depresi di kalangan mahasiswa [2]. Berbagai penelitian menunjukkan bahwa proporsi mahasiswa yang mengalami gejala depresi cukup signifikan dan sering kali tidak teridentifikasi secara dini [3]. Situasi ini, jika tidak dikelola dengan benar, dapat berakibat negatif pada prestasi akademik, interaksi sosial, dan kualitas hidup mahasiswa secara keseluruhan [4].

Seiring berkembangnya teknologi, khususnya dalam bidang ilmu data dan kecerdasan buatan, telah muncul peluang baru untuk mendeteksi gangguan kesehatan mental melalui pendekatan

komputasional [5]. Teknik pembelajaran mesin telah terbukti efektif dalam menganalisis data kompleks dan multidimensional untuk menghasilkan prediksi yang lebih akurat dibandingkan dengan metode statistik konvensional [6]. Model-model ini mampu menganalisis data perilaku, demografis, dan psikososial untuk mengidentifikasi gejala atau pola yang mengindikasikan gangguan seperti depresi [7].

Dua algoritma pembelajaran mesin yang signifikan dalam tugas klasifikasi adalah *decision tree* dan *random forest* [8]. *Decision tree* menyediakan struktur yang sederhana dan mudah dipahami, mirip dengan proses pengambilan keputusan manusia, sehingga memfasilitasi praktisi dalam menafsirkan hasil model [9]. Di sisi lain, *random forest*, sebagai metode ensemble, dapat meningkatkan akurasi prediksi dengan mengintegrasikan hasil dari beberapa *decision tree*, sehingga mengurangi overfitting dan menghasilkan model yang lebih stabil [10].

Penelitian ini bertujuan untuk menganalisis secara komparatif algoritma *decision tree* dan *random forest* dalam mendeteksi gejala depresi pada mahasiswa. Dengan memanfaatkan dataset terbuka yang mencakup respons mahasiswa terhadap berbagai indikator kesehatan mental, kedua model akan dilatih dan dievaluasi untuk menilai efektivitas dan akurasinya. Selain itu, aspek krusial seperti interpretabilitas model dan tingkat kontribusi fitur juga dianalisis untuk mendukung implementasi praktis dalam konteks pendidikan [11].

Penelitian ini diharapkan dapat membantu dalam pengembangan sistem yang memantau kesehatan mental dengan AI. Terutama, penelitian ini menunjukkan bagaimana penggunaan pembelajaran mesin dapat membantu upaya untuk mendeteksi depresi dini pada siswa. Institusi pendidikan dapat menerapkan intervensi yang lebih tepat sasaran untuk meningkatkan kualitas hidup dan kinerja akademik siswa dengan menemukan algoritma yang paling sesuai.

Tinjauan Pustaka

Kesehatan mental mahasiswa telah menjadi fokus utama dalam berbagai penelitian psikologis dan pendidikan tinggi [12]. Menurut [13], depresi merupakan salah satu gangguan mental paling umum yang dialami oleh remaja dan dewasa muda, termasuk mahasiswa. Tekanan akademik yang tinggi, persaingan sosial, serta keterbatasan dukungan emosional seringkali menjadi faktor pemicu gangguan mental. Penelitian oleh [14] menunjukkan bahwa prevalensi depresi dan kecemasan di kalangan mahasiswa mencapai lebih dari 30%, dan banyak dari kasus tersebut tidak mendapatkan penanganan yang memadai. Oleh karena itu, diperlukan strategi baru berbasis teknologi untuk membantu proses skrining dan deteksi dini.

Dalam konteks teknologi, pendekatan machine learning (ML) semakin banyak dimanfaatkan untuk mengidentifikasi masalah kesehatan mental. ML merupakan cabang dari kecerdasan buatan yang memungkinkan sistem komputer belajar dari data dan membuat prediksi atau keputusan tanpa diprogram secara eksplisit. Beberapa penelitian sebelumnya seperti karya [15] menunjukkan bahwa algoritma ML mampu menganalisis data psikologis dan perilaku mahasiswa guna memprediksi risiko depresi dengan tingkat akurasi yang cukup tinggi. Teknik seperti klasifikasi, regresi, dan clustering telah digunakan untuk mengkaji hubungan antara data respon kuesioner dan diagnosis gangguan mental.


Di antara berbagai algoritma machine learning, *decision tree* dan *random forest* merupakan dua metode yang paling banyak digunakan dalam tugas klasifikasi. *Decision tree* membagi data berdasarkan fitur yang paling informatif untuk memprediksi kategori target. Keunggulan utamanya adalah kemudahan interpretasi dan visualisasi proses pengambilan keputusan. Sementara itu, *random forest* adalah metode ensemble yang menggabungkan beberapa pohon keputusan untuk meningkatkan akurasi dan mengurangi overfitting. Beberapa studi, seperti yang dilakukan oleh [15], menunjukkan bahwa *random forest* secara konsisten menghasilkan performa yang lebih tinggi dibandingkan *decision tree* tunggal dalam mendeteksi gangguan psikologis.

Penggunaan kedua algoritma tersebut dalam mendeteksi depresi mahasiswa masih terus dikembangkan, terutama dengan dukungan dataset yang relevan dan berkualitas. Studi oleh [16] menggunakan data media sosial untuk mendeteksi depresi dengan *random forest*, sedangkan Arora dan [17] menggunakan *decision tree* berbasis data survei psikologis. Namun, belum banyak

penelitian yang secara langsung membandingkan kedua algoritma ini dalam konteks data kesehatan mental mahasiswa. Oleh karena itu, kajian ini berupaya mengisi celah tersebut dengan membandingkan kinerja decision tree dan random forest dalam klasifikasi gejala depresi berdasarkan dataset khusus mahasiswa.

Metodologi

Penelitian ini menggunakan pendekatan kuantitatif berbasis eksploratif dan eksperimental yang bertujuan untuk membandingkan kinerja dua algoritma machine learning, yaitu Decision Tree dan Random Forest, dalam klasifikasi kondisi depresi pada mahasiswa. Proses penelitian ini mencakup tahap pengumpulan data, praproses data, pelatihan model, evaluasi performa, serta analisis komparatif terhadap hasil model.



Gambar 1. Diagram Alir Penelitian

Berdasarkan Gambar 1, berikut penjelasan sistematis mengenai tahapan penelitian yang ditunjukkan pada bagan alur tersebut:

A. Pengumpulan Dataset

Dataset yang digunakan dalam penelitian ini diperoleh dari platform Kaggle dengan judul "*Student Depression Decision Tree & Random Forest*." Dataset tersebut memuat informasi mengenai karakteristik mahasiswa serta gejala yang berkaitan dengan kondisi depresi, seperti tekanan akademik, tingkat kecemasan, dan perasaan putus asa. Tahap pengumpulan data ini merupakan fondasi penting sebelum dilakukan pra-pemrosesan dan analisis lebih lanjut, karena kualitas serta kelengkapan data sangat memengaruhi akurasi model *machine learning* yang akan dibangun.

B. Praproses Data

Pada tahap pra-pemrosesan, langkah pertama yang dilakukan adalah pemeriksaan nilai hilang (*missing values*) untuk memastikan tidak ada data kosong yang dapat mengganggu proses pelatihan model. Selanjutnya dilakukan proses pengkodean (*encoding*) untuk mengubah data kategorikal menjadi format numerik yang dapat dipahami oleh algoritma *machine learning*, menggunakan metode seperti *label encoding* atau *one-hot encoding*. Setelah data bersih dan terstruktur, dataset kemudian dibagi menjadi dua bagian, yaitu 80% sebagai data latih (*training set*)

dan 20% sebagai data uji (*testing set*), dengan tujuan untuk melakukan evaluasi dan validasi kinerja model secara objektif.

C. Pelatihan Model

Dalam penelitian ini diterapkan dua algoritma utama, yaitu *Decision Tree* dan *Random Forest*. Algoritma *Decision Tree* merupakan metode klasifikasi yang membangun struktur pohon keputusan berdasarkan karakteristik data untuk menghasilkan prediksi yang logis dan terstruktur. Model ini memiliki keunggulan dalam kemudahan interpretasi karena proses pengambilan keputusannya dapat diikuti secara sistematis melalui percabangan yang jelas. Sebaliknya, *Random Forest* merupakan algoritma *ensemble learning* yang menggabungkan sejumlah pohon keputusan independen untuk memperoleh hasil prediksi yang lebih akurat dan stabil. Dengan mengintegrasikan berbagai *Decision Tree*, *Random Forest* mampu meminimalkan risiko *overfitting* serta memberikan performa yang lebih konsisten dalam menghadapi data dengan pola yang kompleks dan variabilitas yang tinggi.

D. Evaluasi Model

Evaluasi kinerja model dilakukan menggunakan beberapa metrik yang umum digunakan dalam klasifikasi. Metrik pertama adalah akurasi, yang mengukur persentase prediksi benar terhadap keseluruhan data uji. Selain itu, digunakan pula *precision*, *recall*, dan *F1-score*, yang merupakan metrik evaluasi sensitif terhadap ketidakseimbangan data, sehingga mampu memberikan gambaran yang lebih akurat mengenai performa model dalam mengklasifikasikan kasus positif dan negatif. Untuk melengkapi evaluasi, digunakan pula *confusion matrix* yang menunjukkan distribusi hasil prediksi model dalam empat kategori, yaitu *True Positive*, *True Negative*, *False Positive*, dan *False Negative*, sehingga dapat diidentifikasi jenis kesalahan prediksi yang terjadi.

E. Analisis Komparatif

Tahap berikutnya adalah melakukan analisis perbandingan antara algoritma *Decision Tree* dan *Random Forest* berdasarkan hasil evaluasi kinerja yang telah diperoleh. Perbandingan dilakukan dengan menilai kelebihan dan kelemahan masing-masing algoritma dari berbagai aspek, seperti tingkat akurasi, stabilitas model terhadap variasi data, serta kemudahan dalam interpretasi hasil prediksi. Selain itu, dilakukan pula analisis tingkat kepentingan fitur (*feature importance*) untuk mengidentifikasi variabel yang paling berpengaruh dalam memprediksi kondisi depresi, sehingga dapat memberikan wawasan lebih mendalam mengenai faktor-faktor kunci yang memengaruhi kesehatan mental mahasiswa.

F. Kesimpulan dan Saran


Rekomendasi ini diharapkan dapat menjadi dasar penerapan teknologi berbasis *machine learning* dalam upaya preventif terhadap gangguan kesehatan mental di kalangan mahasiswa. Pada tahap akhir penelitian, dilakukan penarikan kesimpulan untuk menentukan algoritma mana yang menunjukkan performa lebih unggul dalam mendeteksi depresi pada mahasiswa, berdasarkan hasil evaluasi dan analisis sebelumnya. Algoritma yang terbukti lebih akurat, stabil, dan efektif kemudian direkomendasikan untuk digunakan dalam pengembangan sistem deteksi dini atau skrining kesehatan mental, khususnya di lingkungan pendidikan tinggi. Rekomendasi ini diharapkan dapat menjadi dasar penerapan teknologi berbasis *machine learning* dalam upaya preventif terhadap gangguan kesehatan mental di kalangan mahasiswa.

Hasil dan Pembahasan

Bagian ini menyajikan hasil analisis dan penerapan algoritma *machine learning* dalam mendeteksi kondisi kesehatan mental mahasiswa. Tahapan yang dibahas meliputi hasil pelatihan dan pengujian dua model utama, yaitu *Decision Tree* dan *Random Forest*, evaluasi kinerja model berdasarkan metrik klasifikasi, serta analisis perbandingan performa keduanya. Selain itu, bagian ini

juga menguraikan interpretasi hasil yang diperoleh melalui analisis tingkat kepentingan fitur (*feature importance*), guna mengidentifikasi variabel-variabel yang paling berpengaruh terhadap kemungkinan munculnya gejala depresi pada mahasiswa.

A. Decision Tree



Gambar 2. Decision Tree Structure

Pada gambar 2 tersebut menunjukkan struktur pohon keputusan (decision tree) yang dibentuk berdasarkan data mahasiswa untuk mengklasifikasikan apakah seorang mahasiswa mengalami depresi (class = 1) atau tidak (class = 0). Pada simpul akar (*root node*), variabel yang menjadi titik awal pemisahan adalah “Apakah Anda pernah memiliki pikiran untuk bunuh diri?”, yang merupakan fitur paling berpengaruh dalam tahap awal klasifikasi. Dari simpul tersebut, pohon kemudian bercabang ke variabel-variabel lain seperti Tekanan Akademik dan Stres Finansial, yang juga memiliki peran penting dalam proses pengambilan keputusan.


Setiap simpul (*node*) menampilkan jumlah sampel, nilai *gini* (tingkat ketidakhomogenan), serta distribusi kelas pada cabang tersebut. Warna pada setiap simpul menggambarkan kecenderungan klasifikasi: biru menunjukkan kelompok mahasiswa yang terindikasi mengalami depresi, sedangkan oranye menandakan mahasiswa yang tidak mengalami depresi. Secara keseluruhan, visualisasi ini memperlihatkan bagaimana algoritma *Decision Tree* mengenali pola-pola depresi berdasarkan kombinasi faktor psikososial dan akademik yang relevan.

Tabel 1. Decision Tree Model Evaluation Results

Parameter	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Rata-rata
Fit Time (s)	0.0487	0.0440	0.0438	0.0438	0.0441	0.0449
Score Time (s)	0.0130	0.0126	0.0128	0.0126	0.0130	0.0128
Test F1 Score	0.8177	0.8175	0.8292	0.8206	0.8234	0.8217
Train F1 Score	0.8227	0.8227	0.8198	0.8220	0.8213	0.8217

Berdasarkan hasil evaluasi model *Decision Tree* menggunakan teknik *5-Fold Cross Validation*, diperoleh nilai rata-rata *F1 Score* pada data uji (*test F1*) sebesar 0,8217. Nilai tersebut menunjukkan bahwa model mampu mengklasifikasikan kondisi depresi mahasiswa dengan tingkat keseimbangan yang baik antara *precision* dan *recall*. Nilai *F1 Score* pada data latih (*train F1*) juga sama, yaitu 0,8217, yang menandakan bahwa model tidak mengalami *overfitting* serta memiliki kinerja yang stabil antara data pelatihan dan data pengujian. Dari sisi efisiensi, waktu rata-rata yang dibutuhkan untuk proses pelatihan (*fit time*) hanya sebesar 0,0449 detik, sedangkan waktu yang diperlukan untuk melakukan prediksi (*score time*) adalah 0,0128 detik. Hasil ini menunjukkan bahwa model *Decision Tree* tidak hanya akurat, tetapi juga memiliki kecepatan dan efisiensi komputasi yang tinggi, sehingga berpotensi digunakan dalam sistem deteksi dini depresi pada mahasiswa secara efektif dan *real-time*.

B. Random Forest



Gambar 3. Data Distribution Visualization

Gambar tersebut memperlihatkan visualisasi distribusi data mahasiswa berdasarkan usia (*Age*) dan IPK kumulatif (CGPA – *Cumulative Grade Point Average*), dengan latar belakang warna yang menggambarkan hasil klasifikasi model terhadap kondisi depresi. Titik berwarna merah dan biru menunjukkan dua kelas mahasiswa, yaitu yang terindikasi mengalami depresi dan yang tidak mengalami depresi. Sementara itu, latar belakang berwarna merah muda dan biru muda merepresentasikan batas keputusan (*decision boundary*) dari model klasifikasi. Terlihat bahwa mahasiswa berusia di bawah 30 tahun (wilayah berwarna merah) memiliki sebaran data yang lebih padat dan bervariasi pada nilai CGPA, serta lebih sering diklasifikasikan ke dalam kelompok yang menunjukkan potensi depresi. Sebaliknya, pada kelompok mahasiswa berusia di atas 30 tahun (wilayah biru), sebagian besar termasuk dalam kategori tidak mengalami depresi, meskipun terdapat beberapa *outlier* dengan nilai CGPA yang rendah. Visualisasi ini menunjukkan bahwa usia (*Age*) berperan penting dalam proses klasifikasi, terutama dalam membedakan kelompok mahasiswa yang berpotensi mengalami gangguan kesehatan mental.

Tabel 2. Random Forest Model Evaluation Result

Parameter	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Rata-rata
Fit Time (s)	0.6707	0.6541	0.6678	0.6697	0.6624	0.6649
Score Time (s)	0.0517	0.0460	0.0465	0.0460	0.0484	0.0477
Test F1 Score	0.8140	0.8165	0.8039	0.8046	0.8089	0.8098
Train F1 Score	0.8083	0.8080	0.8105	0.8127	0.8096	0.8098

Berdasarkan Tabel 4.2, hasil evaluasi model *Random Forest* menggunakan metode *5-Fold Cross Validation* menunjukkan kinerja yang stabil dan cukup tinggi. Nilai rata-rata *F1 Score* pada data uji (*test F1*) sebesar 0,8098, sedangkan pada data latih (*train F1*) juga mencapai 0,8098. Kesamaan nilai tersebut menunjukkan bahwa model memiliki keseimbangan yang baik antara kemampuan generalisasi dan tingkat akurasi dalam melakukan klasifikasi. Waktu pelatihan rata-rata (*fit time*) tercatat sebesar 0,6649 detik, sementara waktu yang dibutuhkan untuk melakukan prediksi (*score time*) adalah sekitar 0,0477 detik. Hasil ini mengindikasikan bahwa meskipun *Random Forest* merupakan model yang lebih kompleks dibandingkan *Decision Tree*, efisiensi komputasinya tetap tergolong baik. Secara keseluruhan, *Random Forest* terbukti menjadi model yang andal dan konsisten dalam mendeteksi potensi depresi pada mahasiswa berdasarkan data yang digunakan.

Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa kedua algoritma *machine learning* yang digunakan, yaitu *Decision Tree* dan *Random Forest*, mampu mengklasifikasikan kondisi depresi pada mahasiswa dengan tingkat akurasi dan nilai *F1 Score* yang tinggi. Meskipun *Decision Tree* menunjukkan hasil yang baik dan efisien dalam hal waktu pelatihan serta kemudahan interpretasi, *Random Forest* unggul dalam hal stabilitas dan akurasi, dengan performa yang lebih konsisten pada setiap lipatan validasi silang (*cross-validation folds*). Nilai rata-rata *F1 Score* untuk *Decision Tree* mencapai 0,8217, sedangkan *Random Forest* berada pada angka 0,8098. Perbedaan keduanya relatif kecil, namun *Random Forest* cenderung lebih tahan terhadap *overfitting* dan lebih akurat dalam menangani data yang kompleks.

Berdasarkan temuan tersebut, *Random Forest* direkomendasikan sebagai model yang lebih andal untuk diterapkan pada sistem deteksi dini depresi mahasiswa, terutama jika tujuan utama adalah memperoleh tingkat akurasi tinggi dan ketahanan terhadap variasi data. Namun demikian, apabila aspek interpretabilitas dan kecepatan eksekusi menjadi prioritas, maka *Decision Tree* tetap merupakan pilihan yang layak. Hasil penelitian ini memperkuat potensi penerapan teknologi *machine learning* sebagai alat pendukung upaya preventif dan intervensi dini dalam bidang kesehatan mental di lingkungan pendidikan tinggi.

Daftar Pustaka

- [1] Chowdhury, M. R., Xuan, W., Sen, S., Zhao, Y., & Ding, Y. (2025). Predicting and Understanding College Student Mental Health with Interpretable Machine Learning. In *ACM/IEEE International Conference on Connected Health: Applications, Systems and Engineering Technologies (CHASE '25)*, June 24–26, 2025, New York, NY, USA (Vol. 1, Nomor 1). Association for Computing Machinery. <https://doi.org/10.1145/3721201.3721372>
- [2] Costa, V. G., & Pedreira, C. E. (2023). Recent advances in decision trees: an updated survey. *Artificial Intelligence Review*, 56(5), 4765–4800. <https://doi.org/10.1007/s10462-022-10275-5>
- [3] Góngora Alonso, S., Marques, G., Agarwal, D., De la Torre Díez, I., & Franco-Martín, M. (2022). Comparison of Machine Learning Algorithms in the Prediction of Hospitalized Patients with Schizophrenia. *Sensors*, 22(7). <https://doi.org/10.3390/s22072517>
- [4] Hyseni Duraku, Z., Davis, H., Arënliu, A., Uka, F., & Behluli, V. (2024). Overcoming mental health challenges in higher education: a narrative review. *Frontiers in psychology*, 15(December), 1466060. <https://doi.org/10.3389/fpsyg.2024.1466060>
- [5] Kristensen, S. M., Larsen, T. M. B., Urke, H. B., & Danielsen, A. G. (2023). Academic Stress, Academic Self-efficacy, and Psychological Distress: A Moderated Mediation of Within-person Effects. *Journal of Youth and Adolescence*, 52(7), 1512–1529.

- <https://doi.org/10.1007/s10964-023-01770-1>
- [6] Lewis, R. A., Ghandeharioun, A., Fedor, S., Pedrelli, P., Picard, R., & Mischoulon, D. (2023). *Mixed Effects Random Forests for Personalised Predictions of Clinical Depression Severity*. <http://arxiv.org/abs/2301.09815>
 - [7] Lorenzoni, G., Tavares, C., Nascimento, N., Alencar, P., & Cowan, D. (2025). Assessing ML classification algorithms and NLP techniques for depression detection: An experimental case study. *PLoS ONE*, 20(5 May). <https://doi.org/10.1371/journal.pone.0322299>
 - [8] Luo, M. M., Hao, M., Li, X. H., Liao, J., Wu, C. M., & Wang, Q. (2024). Prevalence of depressive tendencies among college students and the influence of attributional styles on depressive tendencies in the post-pandemic era. *Frontiers in Public Health*, 12(January), 1–9. <https://doi.org/10.3389/fpubh.2024.1326582>
 - [9] Macalli, M., Castel, L., Jacqmin-Gadda, H., Tournier, M., Galéra, C., Pereira, E., & Tzourio, C. (2024). Frequency of depressive symptoms and suicidal ideation among university students before and after the COVID-19 pandemic. *medRxiv*, 2024.03.14.24304160. <http://medrxiv.org/content/early/2024/03/16/2024.03.14.24304160.abstract>
 - [10] Modi, K., Singh, I., & Kumar, Y. (2023). A Comprehensive Analysis of Artificial Intelligence Techniques for the Prediction and Prognosis of Lifestyle Diseases. *Archives of Computational Methods in Engineering*, 30(8), 4733–4756. <https://doi.org/10.1007/s11831-023-09957-2>
 - [11] Nickson, D., Meyer, C., Walasek, L., & Toro, C. (2023). Prediction and diagnosis of depression using machine learning with electronic health records data: a systematic review. In *BMC Medical Informatics and Decision Making* (Vol. 23, Nomor 1). BioMed Central. <https://doi.org/10.1186/s12911-023-02341-x>
 - [12] Patil, A., Shah, D., Shah, A., & Gala, M. (2023). *A Hybrid Approach for Depression Classification: Random Forest-ANN Ensemble on Motor Activity Signals*. 1–8. <http://arxiv.org/abs/2310.09277>
 - [13] Pichler, M., & Hartig, F. (2023). Machine learning and deep learning—A review for ecologists. *Methods in Ecology and Evolution*, 14(4), 994–1016. <https://doi.org/10.1111/2041-210X.14061>
 - [14] Raharja, A. R., Putra, V. H. C., Kanugrahan, G., & Tho, C. (2024). Indonesian Sign Language (SIBI) Detection: A Landmark-Based Approach with Scikit-Learn Utilizing Random Forest Classifier. *2024 Ninth International Conference on Informatics and Computing (ICIC)*, 1–8. <https://doi.org/10.1109/ICIC64337.2024.10956917>
 - [15] Schaab, B. L., Calvetti, P. Ü., Hoffmann, S., Diaz, G. B., Rech, M., Cazella, S. C., Stein, A. T., Barros, H. M. T., da Silva, P. C., & Reppold, C. T. (2024). How do machine learning models perform in the detection of depression, anxiety, and stress among undergraduate students? A systematic review. *Cadernos de Saude Publica*, 40(11). <https://doi.org/10.1590/0102-311XEN029323>
 - [16] Shahhosseini, M., & Hu, G. (2021). *Improved Weighted Random Forest for Classification Problems*. 42–56. https://doi.org/10.1007/978-3-030-66501-2_4
 - [17] Siwinska, N., & Bergen, J. (2025). *Replicating "Detection of Depression-Related Posts in Reddit Social Media Forum" Data Scraping / Pre-processing*.